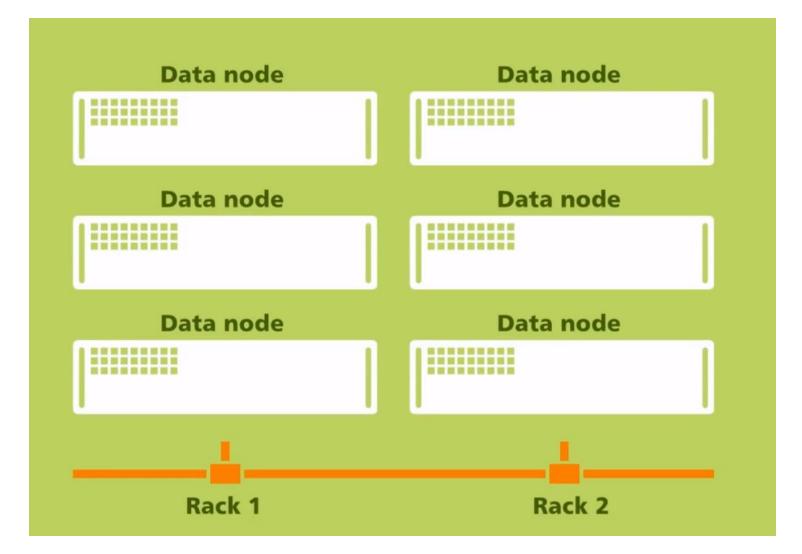
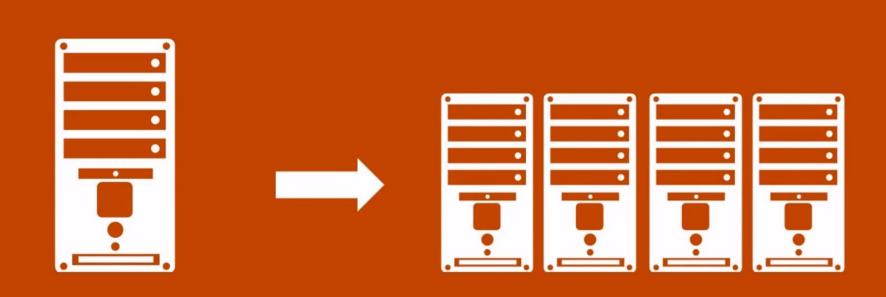
Apache Hadoop

Jorge Siqueira

William Thiago







Escalabilidade Horizontal (scale out)

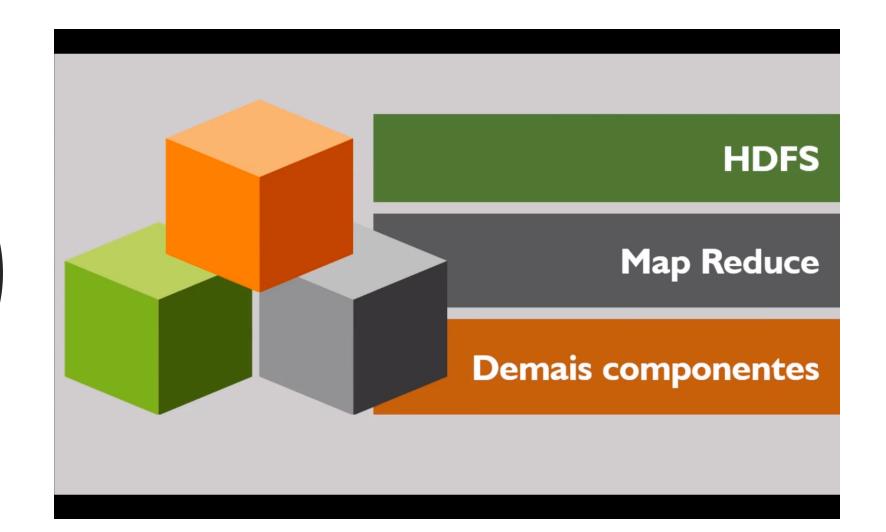


Família de projetos relacionados

Infra
estrutura de
computação
distribuída

Processamento de dados de larga escala





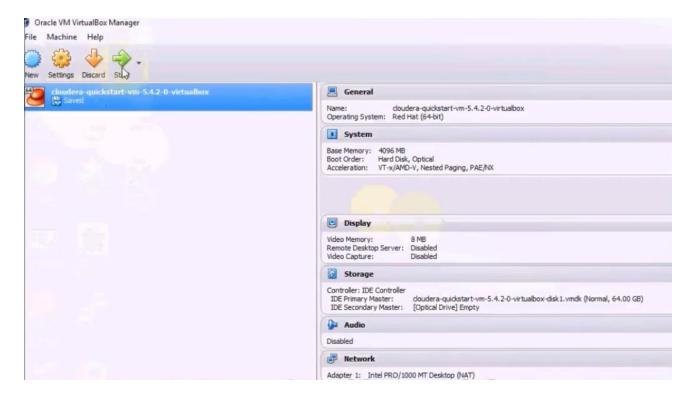
Fazer uma consulta de dados em clusters



Rodando programas Hadoop

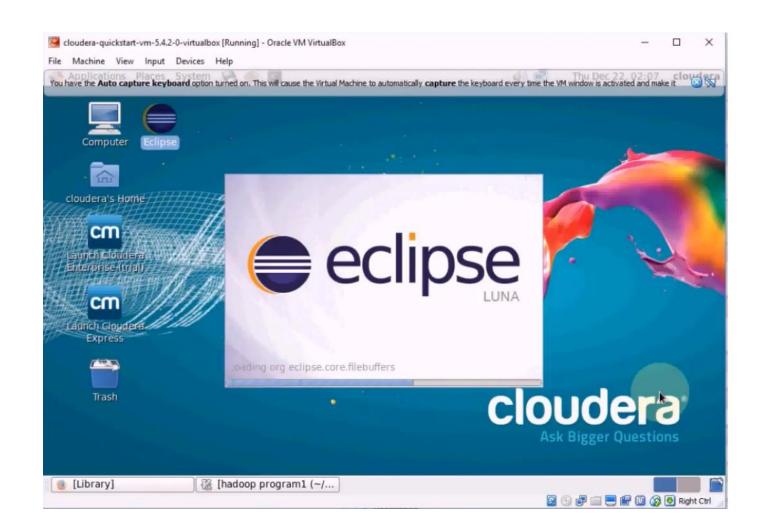
Primeiro baixamos a Oracle virtual machine (virtual box) para rodar o nosso framework hadoop, quem já vem instalado no S.O linux da empresa Cloudera, disponível

em: https://www.cloudera.com/

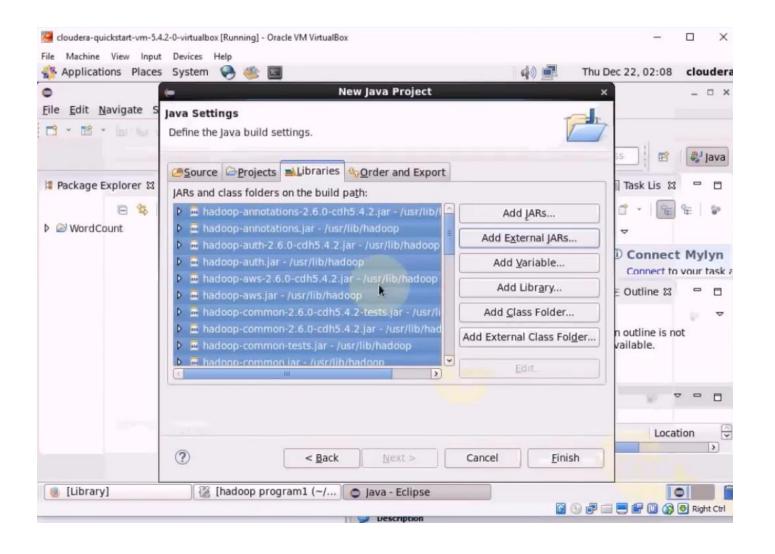


Após isso realizamos a instalação da máquina virtual e executamos.

Após isso, já dentro do Cloudera, abrimos a IDE eclipse, que já veio instalada na VM, para podermos criar o jar file, que será o map reduce do nosso exemplo.



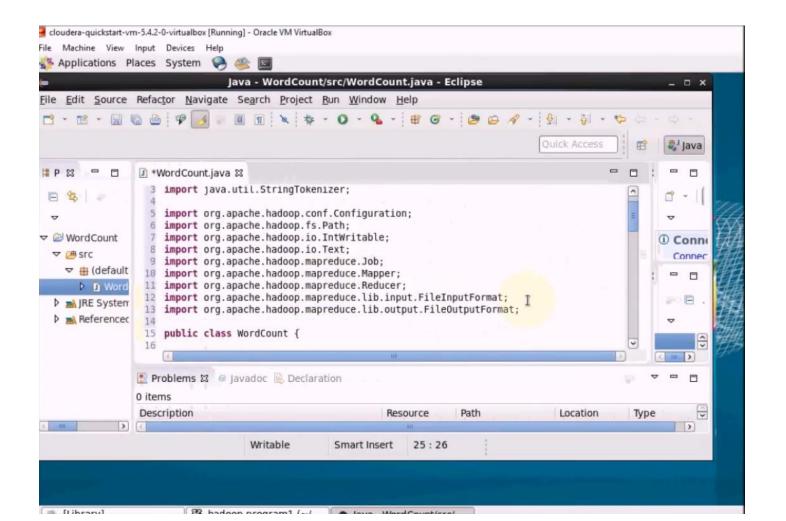
Após isso, criamos um novo arquivo java em branco, e importamos todas as bilbiotecas hadoop, e as bibliotecas externas do hadoop também.



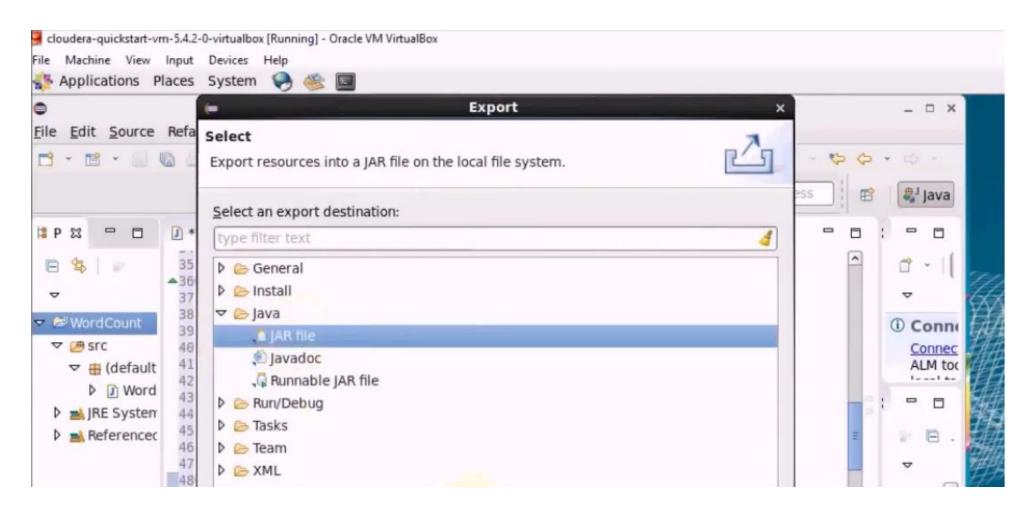
Após isso, copiamos e colamos um script java, que é o nosso map reduce. Esse script irá receber uma lista de palavras, eirá contar quantas vezes cada palavra se repete na lista.

O script completo está disponível em:

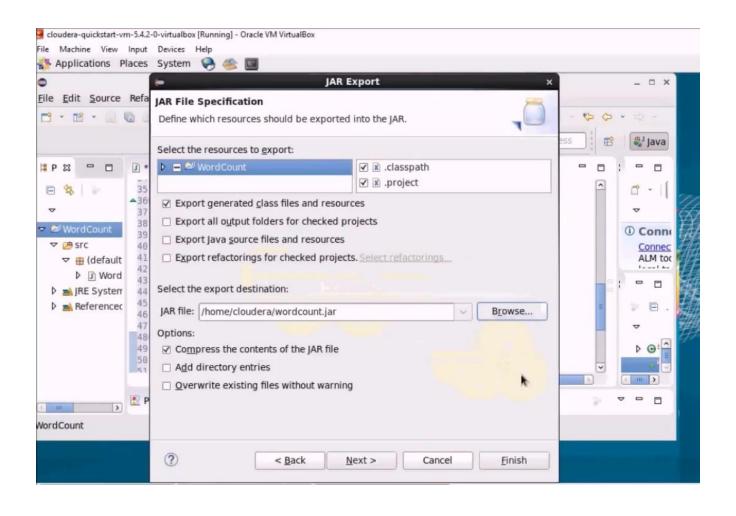
https://github.com/dbtsai/hadoop-word-count/blob/master/mapreduce/src/main/java/com/dbtsai/hadoop/mapreduce/WordCountMR.java



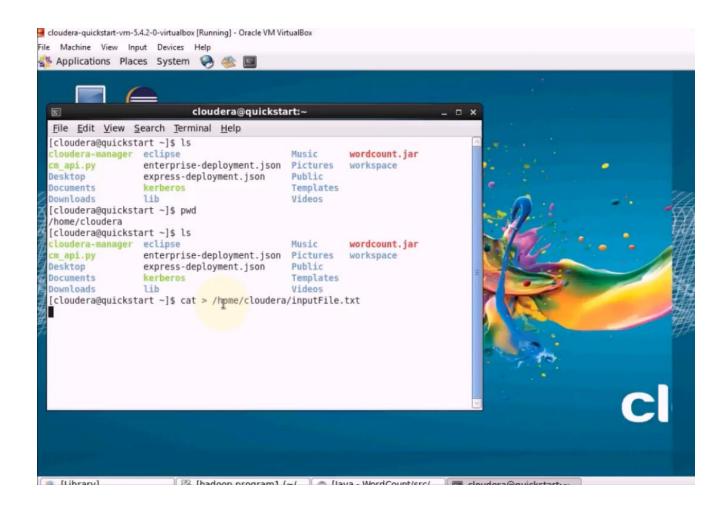
Após isso, clicamos com o botão direito sobre o projeto do eclipse, e exportamos o projeto no formato .jar file, que é um arquivo reconhecido pelo hadoop para realizar o mapreduce



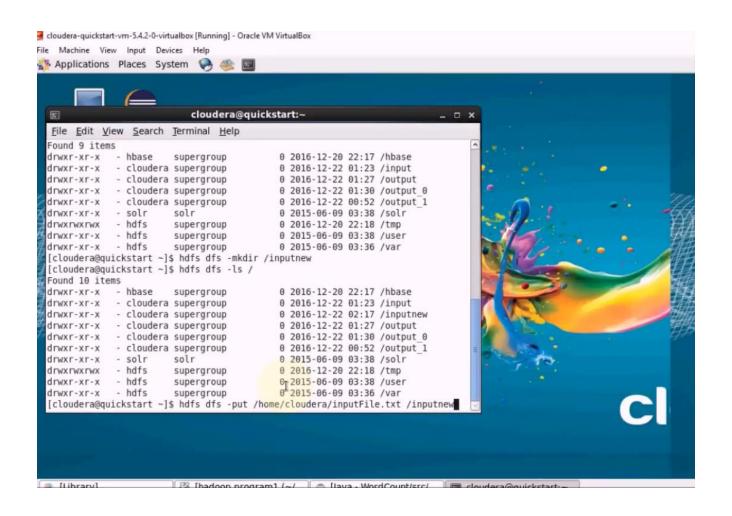
Após isso, indicamos o local de salvamento do arquivo gerado, que é na pasta raíz do cloudera (HOME).



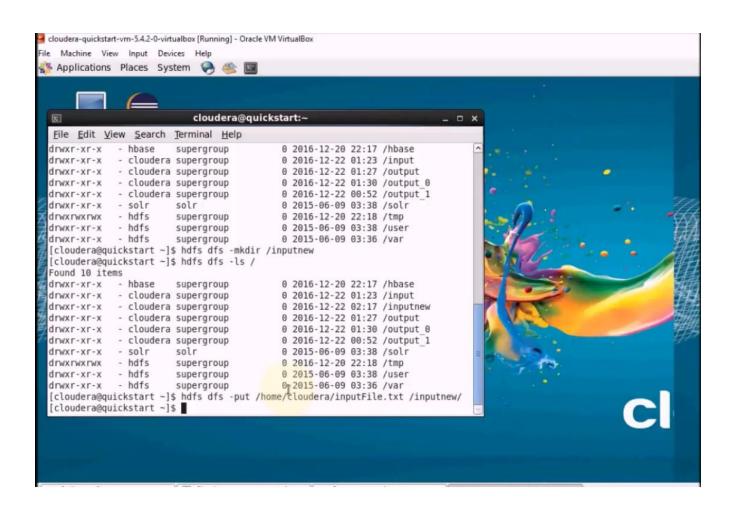
Após isso, usando o terminal do cloudera, criamos um arquivo de texto, que será o nosso input file, nele escrevemos as palavras que queremos contar.



Após isso, salvamos o inputfile.txt na pasta raíz.



Após isso, por meio do hadoop executamos o arquivo jar, e indicamos onde está o script java, a classe, o input e a saída que queremos.



Após isso, analisamos o outputfile, que é o resultado que buscamos.

